



UNIVERSITÉ MOHAMMED PREMIER
FACULTÉ DES SCIENCES
Département d'Informatique



RAPPORT DU MINI PROJET

IA appliquée à la santé

Classification de 8 pathologies à partir de 5 symptômes

Module : Data Mining

Master Intelligence Artificielle et Sciences des Données

RÉALISÉ PAR

- Nom et Prénom : KAZDABI NBARK
Code Massar : *****
Code Apogée : *****
- Nom et Prénom : JAIL HAMID
Code Massar : *****
Code Apogée : *****

ENCADRÉ PAR

Mr. Aissa KERKOUR El MIAD

ANNÉE UNIVERSITAIRE : 2025 – 2026

Table des matières

1	Introduction	5
2	Présentation des données sources et du sujet d'analyse	7
2.1	Présentation du sujet	7
2.1.1	Points clés à retenir pour cette section	8
2.2	Description du dataset	8
2.3	Environnement Orange	9
3	Analyse descriptive des données	11
3.1	Analyse univariée	11
3.1.1	Box Plot :	11
3.1.2	Column Statistics :	12
3.2	Analyse bivariée	12
3.2.1	Scatter Plot (Fever vs Headache)	13
3.2.2	Mosaic Display (Body-Pain vs Disease)	13
4	Prétraitement des données (Data Preprocessing)	15
4.1	Sélection des colonnes	15
4.2	Détection des valeurs aberrantes (Outliers)	16
4.3	Imputation des valeurs manquantes	18
4.4	Normalisation des données	19
5	Sélection des caractéristiques et réduction de dimension	21
5.1	Classement des variables (Rank)	21
5.2	Projection linéaire (Linear Projection)	22
5.3	Matrice de corrélation (Heat Map)	23
5.4	Analyse en Composantes Principales (PCA)	24
5.5	Visualisation des composantes principales (Scatter Plot PCA)	26
6	Modélisation et évaluation des performances	28
6.1	Modèles supervisés (Test et Score)	28
6.1.1	analyse des résultats	29
6.1.2	Conclusion sur les modèles supervisés	29
6.2	Analyse approfondie des performances	29
6.2.1	Matrice de confusion	30
6.2.2	Courbes ROC (Receiver Operating Characteristic)	30
6.2.3	Courbes de performance (Performance Curve)	31
6.2.4	Synthèse des évaluations	31
6.3	Clustering non supervisé (K-means)	32

6.3.1	Visualisation des clusters (Scatter Plot)	33
7	Extraction de connaissances	35
7.1	L'arbre de décision	35
7.2	Classification Ascendante Hiérarchique (CAH)	39
7.2.1	Construction du dendrogramme (Hierarchical Clustering)	42
8	Conclusion	45

Table des figures

2.1	Les informations sur les donnees du Dataset	8
2.2	Les informations du Dataset	9
2.3	Workflow complet réalisé sous Orange pour l'analyse et la classification des données médicales.	10
3.1	Box PLOT - Orange	11
3.2	Column Statistics - Orange	12
3.3	Relation entre la fièvre (Fever) et les maux de tête (Headache) à l'aide du widget Scatter Plot.	13
3.4	Répartition des douleurs corporelles selon les différentes maladies à l'aide du widget Mosaic Display.	14
4.1	Sélection des colonnes pertinentes pour l'analyse à l'aide du widget Select Columns dans Orange.	16
4.2	Détection des valeurs aberrantes à l'aide du widget Outliers dans Orange utilisant la méthode Local Outlier Factor (LOF).	17
4.3	Gestion des valeurs manquantes à l'aide du widget Impute dans Orange, proposant différentes méthodes d'imputation.	19
4.4	Normalisation des données à l'aide du widget Preprocess dans Orange pour harmoniser les échelles des variables.	20
5.1	Classement des variables (Rank) selon leur pouvoir discriminant vis-à-vis de la maladie cible à l'aide de différentes méthodes (Information Gain, Gini Decrease, ANOVA, ReliefF).	21
5.2	Projection linéaire des données utilisant LDA dans Orange, montrant la séparation des différentes maladies dans un espace à deux dimensions.	23
5.3	Matrice de corrélation des symptômes à l'aide du widget Heat Map dans Orange, illustrant les relations entre les variables.	24
5.4	Projection des données en deux dimensions à l'aide de l'Analyse en Composantes Principales (PCA) dans Orange, illustrant la variance expliquée et la structure des données.	25
5.5	Projection des données sur les deux premières composantes principales (PCA) sous forme de Scatter Plot, illustrant la répartition des patients et la séparabilité des différentes maladies dans un espace réduit.	26
6.1	Les modeles Utiliser	28
6.2	Les Modeles Resultats	29
6.3	Matrice de Confusion	30
6.4	Courbes ROC (Receiver Operating Characteristic)	30
6.5	Courbes de performance (Performance Curve)	31

6.6	Synthèse des évaluations	31
6.7	Résultat du clustering K-means appliqué aux données patients, illustrant la formation de groupes basés sur la similarité des symptômes dans un espace réduit.	32
6.8	K-means parametres	33
6.9	Projection des patients sur les deux premières composantes principales (PC1 et PC2) avec coloration selon les 8 clusters (C1 à C8) obtenus par K-means.	33
6.10	Visualisation des clusters (Scatter Plot)	34
7.1	Select Columns	36
7.2	Tree	37
7.3	Parametre de l'arbre	37
7.4	Arbre de decision	38
7.5	Regle extrait de l'arbre	38
7.6	Classification Ascendante Hiérarchique (CAH)	40
7.7	Distance	41
7.8	Distance Parametres	41
7.9	Hierarchical Clustering	42
7.10	Hierarchical Clustering Informations	42
7.11	Visualisation des clusters (Scatter Plot)	43
7.12	Les informations sur Visualisation des clusters	44

Chapitre 1

Introduction

Dans le cadre du module Data Mining du Master IASD (2025/2026), ce projet vise à développer une approche d'extraction de connaissances appliquée au diagnostic médical assisté par intelligence artificielle. La problématique centrale de cette étude est la suivante : comment prédire efficacement la maladie d'un patient à partir d'un ensemble limité de cinq symptômes cliniques (fièvre, maux de tête, toux, fatigue et douleurs corporelles), tout en garantissant des performances de classification robustes et une interprétabilité des résultats pour une utilisation en contexte médical ? Pour répondre à cette question, nous disposons d'un dataset synthétique de 5 000 patients, équilibré entre huit pathologies courantes (rhume, paludisme, toux, asthme, fièvre normale, courbatures, écoulement nasal et dengue), qui offre un cadre contrôlé pour évaluer différentes techniques de data mining.

La démarche adoptée s'articule autour de deux axes complémentaires. D'une part, nous avons utilisé Orange, un environnement de visualisation et d'analyse par workflow, pour réaliser une exploration préliminaire des données. Le pipeline Orange a permis le chargement des données, l'analyse descriptive (univariée et bivariée) via des graphiques interactifs (distributions, boîtes à moustaches, mosaïques et nuages de points), le prétraitement (détection des outliers, imputation des valeurs manquantes, sélection des caractéristiques par la méthode Rank), ainsi qu'une première évaluation de modèles supervisés (Naive Bayes, kNN, Random Forest, réseau de neurones, SVM et régression logistique) à l'aide de matrices de confusion et de courbes ROC. Par ailleurs, le workflow Orange intègre des techniques non supervisées telles que l'analyse en composantes principales (PCA), le clustering k-means avec évaluation par coefficient de silhouette, et la classification ascendante hiérarchique (CAH) couplée à une projection PCA pour la visualisation des clusters.

D'autre part, pour répondre aux limitations d'Orange et approfondir l'analyse, nous avons développé un script Python complet reprenant et enrichissant les étapes du workflow. Ce script a permis d'ajouter des fonctionnalités avancées comme l'application de la technique SMOTE (pour simuler et corriger un déséquilibre des classes), l'implémentation de réseaux bayésiens pour l'inférence probabiliste, l'extraction de règles d'association (Apriori), et une évaluation comparative approfondie des modèles avec des métriques détaillées (précision, rappel, F1-score, AUC, temps d'entraînement). L'ensemble de cette démarche a abouti à des résultats prometteurs : le modèle Random Forest atteint une précision de classification supérieure à 95%, confirmant la pertinence des symptômes sélectionnés pour le diagnostic, tandis que les réseaux bayésiens et les règles d'association offrent des pistes d'interprétation clinique utiles pour la prise de décision médicale. La synthèse de ces deux approches (Orange pour l'exploration visuelle et Python pour l'ana-

lyse approfondie) constitue une méthodologie complète et reproductible, alliant puissance de calcul, interprétabilité et rigueur scientifique.

Chapitre 2

Présentation des données sources et du sujet d'analyse

2.1 Présentation du sujet

Le diagnostic médical constitue l'une des applications les plus prometteuses de l'intelligence artificielle dans le domaine de la santé. Face à la complexité croissante des données cliniques et à la nécessité d'une prise de décision rapide et fiable, les techniques de data mining et d'apprentissage automatique offrent des outils puissants pour assister les professionnels de santé dans l'identification des pathologies à partir de symptômes observés.

Dans ce contexte, notre projet s'inscrit dans une démarche de diagnostic médical assisté par intelligence artificielle à partir de cinq symptômes cliniques : la fièvre, les maux de tête, la toux, la fatigue et les douleurs corporelles. L'objectif est de prédire la maladie dont souffre un patient parmi huit affections courantes, à savoir le rhume, le paludisme, la toux, l'asthme, la fièvre normale, les courbatures, l'écoulement nasal et la dengue.

Ce sujet présente un double intérêt :

- **Sur le plan médical :** Il s'agit d'un problème concret de classification où les symptômes constituent des indicateurs clés pour orienter le diagnostic. La capacité à prédire automatiquement une maladie à partir de quelques symptômes pourrait, à terme, faciliter le triage des patients et améliorer la rapidité de la prise en charge, notamment dans les zones où l'accès aux médecins est limité. ““
- **Sur le plan méthodologique :** Ce problème de classification multiclasse est idéal pour illustrer et comparer différentes techniques de data mining vues dans le cours. Il permet de mettre en œuvre l'ensemble de la chaîne de traitement des données, depuis le prétraitement jusqu'à l'évaluation des modèles, en passant par l'analyse exploratoire et l'extraction de connaissances. ““

Le dataset utilisé, composé de 5 000 patients synthétiques, est particulièrement adapté à ce projet car il offre un cadre équilibré et contrôlé pour tester les algorithmes, tout en présentant des corrélations médicalement réalistes entre les symptômes et les maladies. Bien que synthétique, ce jeu de données simule des relations cliniques qui permettent d'évaluer la pertinence des approches d'apprentissage automatique dans un contexte proche de la pratique médicale réelle.

2.1.1 Points clés à retenir pour cette section

- Contexte : Diagnostic médical assisté par IA
- Objectif : Prédire la maladie à partir de 5 symptômes
- 8 classes de maladies
- Double intérêt : médical (aide au diagnostic) et méthodologique (application des techniques de data mining)
- Dataset synthétique mais réaliste de 5 000 patients

2.2 Description du dataset

Le jeu de données utilisé dans ce projet est un ensemble de données synthétiques, généré à l'aide des bibliothèques Python NumPy et Pandas. Sa conception repose sur des corrélations médicales réalistes entre les symptômes et les maladies, afin de reproduire des tableaux cliniques cohérents tout en offrant un cadre contrôlé pour l'évaluation des modèles d'apprentissage automatique.

Le dataset est structuré sous forme d'un fichier CSV contenant 5 000 enregistrements (patients) et 6 colonnes. Cinq variables correspondent aux symptômes cliniques, toutes de type numérique continu, tandis que la sixième variable représente la maladie diagnostiquée, de type catégoriel. La description détaillée des variables est la suivante :

Variable	Type	Description	Plage de valeurs
Fever	Float (numérique continu)	Température corporelle en degrés Fahrenheit	95 - 105 °F
Headache	Float (numérique continu)	Intensité des maux de tête (échelle subjective)	0 - 10
Cough	Float (numérique continu)	Intensité de la toux (échelle subjective)	0 - 10
Fatigue	Float (numérique continu)	Niveau de fatigue ressentie (échelle subjective)	0 - 10
Body_Pain	Float (numérique continu)	Intensité des douleurs corporelles (échelle subjective)	0 - 10
Disease	String (catégorielle nominale)	Maladie diagnostiquée	8 classes distinctes

FIGURE 2.1 – Les informations sur les données du Dataset

La variable cible **Disease** comprend huit pathologies courantes, à savoir : Body Ache (courbatures), Common Cold (rhume), Cough (toux persistante), Asthma (asthme), Normal Fever (fièvre sans pathologie associée), Runny Nose (écoulement nasal), Malaria (paludisme) et Dengue (dengue). Le dataset présente une répartition parfaitement équilibrée des classes, avec 625 patients par maladie, soit 12,5% de l'effectif total pour chaque pathologie. Cet équilibre constitue un avantage significatif pour l'apprentissage supervisé, car il évite les biais liés au déséquilibre des classes et permet une évaluation objective des performances des modèles de classification.

Les informations générales sur le dataset peuvent être consultées à l'aide du widget Data Info dans Orange, en le reliant au widget File qui assure le chargement des données.




FIGURE 2.2 – Les informations du Dataset

2.3 Environnement Orange

La figure ci-dessous présente le workflow complet réalisé sous Orange. Ce pipeline illustre l'ensemble du processus d'analyse, depuis le chargement des données jusqu'à l'évaluation des modèles de classification. Les étapes successives comprennent : l'importation du fichier CSV via le widget `File`, l'inspection préliminaire des données à l'aide des widgets `Data Info` et `Data Table`, l'analyse descriptive via les widgets `Distributions`, `Box Plot` et `Scatter Plot`, le prétraitement des données avec les widgets `Outliers`, `Impute` et `Preprocess`, la sélection des caractéristiques via le widget `Rank`, la réduction de dimension par PCA, le clustering avec `k-Means` et `Hierarchical Clustering`, ainsi que la modélisation prédictive et l'évaluation des performances à l'aide des widgets `Test Score`, `Confusion Matrix` et `ROC Analysis`.




FIGURE 2.3 – Workflow complet réalisé sous Orange pour l’analyse et la classification des données médicales.

Chapitre 3

Analyse descriptive des données

3.1 Analyse univariée

L'analyse univariée constitue la première étape de l'exploration des données. Elle consiste à étudier chaque variable de manière individuelle, indépendamment des autres, afin d'en comprendre la distribution, la tendance centrale et la dispersion. Cette approche permet d'identifier les caractéristiques fondamentales du dataset, de détecter d'éventuelles anomalies et d'orienter les choix méthodologiques pour les analyses ultérieures.

3.1.1 Box Plot :




FIGURE 3.1 – Box PLOT - Orange

Le widget Box Plot permet de visualiser graphiquement la distribution de chaque symptôme. On observe que Body-Pain présente la plus grande dispersion, avec des valeurs s'étendant de 0 à près de 10 et une médiane relativement basse (1,62), suggérant que la plupart des patients ressentent peu de douleurs corporelles, mais que certains cas

présentent des douleurs très intenses. Fever, en revanche, montre une distribution resserrée autour de 99–100°F, avec quelques valeurs extrêmes correspondant aux cas de fièvre élevée (malaria, dengue). La présence de valeurs aberrantes, notamment pour Body-Pain et Cough, indique des cas cliniques particulièrement sévères qui mériteront une attention particulière lors du prétraitement.

3.1.2 Column Statistics :




FIGURE 3.2 – Column Statistics - Orange

Le widget Column Statistics fournit les principaux indicateurs statistiques pour chaque symptôme. La fièvre présente une moyenne de 99,82°F avec une dispersion très faible (0,02), indiquant une concentration des valeurs autour de la moyenne. Les symptômes subjectifs (Headache, Cough, Fatigue, Body-Pain) montrent des dispersions plus importantes, avec des moyennes variant de 2,62 à 5,06. L'absence totale de valeurs manquantes confirme la complétude du dataset.

Ces analyses préliminaires confirment la cohérence des données générées et orientent les choix méthodologiques pour les étapes ultérieures de l'étude.

3.2 Analyse bivariée

L'analyse bivariée examine les relations entre deux variables simultanément, permettant d'identifier d'éventuelles corrélations ou associations entre les symptômes et les maladies. Dans le cadre de ce projet, cette analyse a été réalisée à l'aide de deux widgets Orange : Scatter Plot et Mosaic Display.

3.2.1 Scatter Plot (Fever vs Headache)

Le nuage de points présenté ci-dessus illustre la relation entre la fièvre (Fever) et les maux de tête (Headache). On observe que les patients présentant des températures élevées (supérieures à 103°F) ont tendance à avoir des maux de tête plus intenses (supérieurs à 7/10). Cette association est particulièrement marquée pour les cas de dengue et de paludisme, où les deux symptômes sont généralement sévères. À l'inverse, les patients avec une température normale (autour de 98°F) présentent des maux de tête faibles à modérés, ce qui correspond aux cas de fièvre normale ou de rhume banal. Cette visualisation confirme la corrélation positive attendue entre ces deux symptômes dans un contexte clinique réaliste.




FIGURE 3.3 – Relation entre la fièvre (Fever) et les maux de tête (Headache) à l'aide du widget Scatter Plot.

3.2.2 Mosaic Display (Body-Pain vs Disease)

Le diagramme en mosaïque ci-dessus montre la répartition des douleurs corporelles (Body-Pain) selon les différentes maladies. On observe que la classe Body Ache se distingue nettement avec une proportion élevée de patients présentant des douleurs corporelles intenses (catégorie 5.99). Les couleurs rouges (Pearson residuals positifs) indiquent une surreprésentation significative de cette association. À l'opposé, les maladies comme Normal Fever et Runny Nose montrent une sous-représentation des douleurs corporelles sévères (couleurs bleues). Cette analyse confirme que la douleur corporelle est un symptôme discriminant pour certaines pathologies, en particulier pour les courbatures (Body Ache) et la dengue.




FIGURE 3.4 – Répartition des douleurs corporelles selon les différentes maladies à l'aide du widget Mosaic Display.

Chapitre 4

Prétraitement des données (Data Preprocessing)

4.1 Sélection des colonnes

La première étape du prétraitement consiste à sélectionner les variables pertinentes pour l'analyse, à l'aide du widget *Select Columns* dans Orange. Comme illustré ci-dessus, ce widget permet de définir le rôle de chaque variable dans le processus d'analyse :




FIGURE 4.1 – Sélection des colonnes pertinentes pour l’analyse à l’aide du widget Select Columns dans Orange.

Features (5) : Les cinq symptômes cliniques (Fever, Headache, Cough, Fatigue, Body_Pain) sont désignés comme variables explicatives (features). Ce sont les variables d’entrée qui seront utilisées par les modèles pour prédire la maladie.

Target (1) : La variable *Disease* est définie comme variable cible (target). Il s’agit de la variable que l’on souhaite prédire, représentant les huit pathologies diagnostiquées.

Ignored / Metas : Aucune variable n’est ignorée ou définie comme métadonnée dans cette configuration. Toutes les variables disponibles sont utilisées dans l’analyse.

4.2 Détection des valeurs aberrantes (Outliers)

La détection des valeurs aberrantes, ou *outliers*, est une étape cruciale du prétraitement des données. Ces observations atypiques peuvent résulter d’erreurs de saisie, de cas cliniques exceptionnels ou de bruits dans les données. Bien qu’elles puissent contenir des informations précieuses, elles risquent également de fausser les résultats des modèles statistiques et d’apprentissage automatique en influençant excessivement les paramètres estimés.

Pour identifier ces points atypiques, nous avons utilisé le widget *Outliers* d’Orange avec la méthode *Local Outlier Factor (LOF)*. Cette technique repose sur le principe suivant : pour chaque observation, elle évalue la densité de ses voisins par rapport à sa propre

densité. Un point est considéré comme aberrant si sa densité locale est significativement plus faible que celle de ses voisins, indiquant qu'il se trouve dans une région peu dense de l'espace des caractéristiques.




FIGURE 4.2 – Détection des valeurs aberrantes à l’aide du widget Outliers dans Orange utilisant la méthode Local Outlier Factor (LOF).

Dans notre cas, la méthode LOF a été paramétrée avec un taux de contamination de 10% et un nombre de voisins fixé à 20, en utilisant la distance euclidienne comme métrique. L’application de cette méthode sur notre dataset de 5 000 patients a permis d’identifier 431 cas comme outliers, soit environ 8,6% de l’effectif total.

Ces 431 outliers correspondent probablement à des patients présentant des combinaisons de symptômes particulièrement sévères ou atypiques, comme une fièvre très élevée associée à une fatigue intense ou des douleurs corporelles extrêmes. Dans un contexte médical, ces cas ne doivent pas être systématiquement éliminés, car ils peuvent représenter des situations cliniques rares mais réelles, comme des formes graves de dengue ou de paludisme.

La décision de conserver ou de supprimer ces outliers sera prise lors des étapes de modélisation, en fonction de leur impact sur les performances des algorithmes. Cette détection préliminaire nous alerte cependant sur la présence d’une variabilité importante

dans les données, qui devra être prise en compte lors de la normalisation et de l'évaluation des modèles.

4.3 Imputation des valeurs manquantes

L'imputation des valeurs manquantes est une étape essentielle du prétraitement, car la plupart des algorithmes d'apprentissage automatique ne peuvent pas traiter directement des données incomplètes. Bien que notre dataset soit dépourvu de valeurs manquantes, le widget *Impute* d'Orange a été intégré au workflow pour anticiper d'éventuelles données incomplètes et pour respecter la chaîne de traitement standard.

Le widget *Impute* propose plusieurs méthodes pour traiter les valeurs manquantes, notamment l'imputation par la moyenne ou la médiane (*Average/Most frequent*), l'imputation par un modèle (*Model-based imputer*), l'assignation aléatoire (*Random values*) ou la suppression des instances concernées (*Remove instances with unknown values*).




FIGURE 4.3 – Gestion des valeurs manquantes à l’aide du widget Impute dans Orange, proposant différentes méthodes d’imputation.

Dans notre cas, aucune valeur manquante n’a été détectée dans le dataset, comme l’illustre la configuration du widget où toutes les variables sont cochées par défaut sans qu’aucune imputation ne soit nécessaire. L’option *Don’t impute* pourrait être appliquée, mais nous avons conservé le paramétrage par défaut (*Average/Most frequent*) qui aurait été utilisé en cas de données incomplètes.

4.4 Normalisation des données

Après l’imputation des valeurs manquantes, le widget *Preprocess* permet d’appliquer différentes transformations aux données afin de les préparer pour les algorithmes d’apprentissage automatique. La normalisation est une étape particulièrement importante lorsque les variables utilisées sont exprimées dans des échelles différentes, comme c’est le cas dans notre dataset : la température corporelle varie entre 97°F et 105°F, tandis que les autres

symptômes sont mesurés sur des échelles de 0 à 10.




FIGURE 4.4 – Normalisation des données à l’aide du widget Preprocess dans Orange pour harmoniser les échelles des variables.

Pour notre analyse, nous avons choisi la méthode *Standardize to $\mu = 0$, $\sigma^2 = 1$* , également appelée standardisation ou normalisation Z-score. Cette technique transforme chaque variable en lui soustrayant sa moyenne et en divisant par son écart-type, de sorte qu’elle ait une moyenne de 0 et un écart-type de 1. Cette transformation présente l’avantage de préserver la forme de la distribution tout en rendant les variables comparables.


Cette normalisation est particulièrement adaptée aux méthodes qui reposent sur des calculs de distance, comme le k-means ou le k-NN, ainsi qu’à certains modèles linéaires sensibles à l’échelle des variables. En standardisant les symptômes, on évite que la fièvre, en raison de ses valeurs numériques plus élevées, ne domine artificiellement les autres variables dans les calculs de distance ou les coefficients de régression. La normalisation permet ainsi une contribution équilibrée de chaque symptôme dans les modèles prédictifs, améliorant leur performance et leur interprétabilité.

Chapitre 5

Sélection des caractéristiques et réduction de dimension

5.1 Classement des variables (Rank)

Après le prétraitement des données, nous avons utilisé le widget *Rank* pour évaluer l'importance prédictive de chaque symptôme. Ce widget applique plusieurs méthodes de scoring permettant de classer les variables selon leur pouvoir discriminant vis-à-vis de la maladie cible. Les méthodes utilisées incluent l'*Information Gain*, le *Gini Decrease*, l'*ANOVA* et *ReliefF*, chacune offrant une perspective différente sur la pertinence des caractéristiques.



	#	In...in	Gain ratio	Gini	ANOVA	ReliefF
1	N Fever	1.056	0.528	0.165	5128.840	0.191
2	N Body_Pain	0.967	0.484	0.157	5637.198	0.200
3	N Headache	0.939	0.469	0.145	2868.781	0.144
4	N Fatigue	0.893	0.446	0.146	2846.054	0.138
5	N Cough	0.832	0.416	0.119	4300.269	0.212

FIGURE 5.1 – Classement des variables (Rank) selon leur pouvoir discriminant vis-à-vis de la maladie cible à l'aide de différentes méthodes (Information Gain, Gini Decrease, ANOVA, ReliefF).

Les résultats obtenus placent systématiquement la *Fièvre (Fever)* en tête du classement, suivie des *Douleurs corporelles (Body_Pain)* et des *Maux de tête (Headache)*. La *Fatigue* et la *Toux (Cough)* occupent respectivement les quatrième et cinquième positions.

Ce classement est cohérent avec les connaissances médicales : la fièvre est un symptôme cardinal dans de nombreuses pathologies, particulièrement discriminante pour des maladies comme la dengue, le paludisme ou la fièvre normale. Les douleurs corporelles distinguent efficacement les courbatures des autres affections, tandis que les maux de tête sont particulièrement marqués dans la dengue et le paludisme.

La toux, bien que pertinente, apparaît comme le symptôme le moins discriminant, ce qui s'explique par sa présence modérée dans plusieurs pathologies (rhume, asthme, toux simple) sans être spécifique à une maladie particulière.

Ces résultats confirment que l'ensemble des cinq symptômes est utile pour la classification, mais que certains, comme la fièvre, contribuent davantage à la discrimination entre les huit maladies. Ce classement guidera nos choix lors de la sélection des caractéristiques pour les modèles prédictifs, bien que nous ayons conservé l'intégralité des variables pour une évaluation complète.

5.2 Projection linéaire (Linear Projection)

Après avoir identifié les variables les plus discriminantes via le widget *Rank*, nous avons utilisé le widget *Linear Projection* pour visualiser la séparabilité des différentes maladies dans un espace à deux dimensions. Cette technique de projection linéaire permet de représenter les données de manière à maximiser la séparation entre les classes, offrant ainsi une vision intuitive de la structure des données.

Le widget *Linear Projection* propose deux méthodes principales : l'*Analyse Discriminante Linéaire (LDA)*, qui cherche à maximiser la séparation entre les classes en projetant les données sur des axes qui discriminent au mieux les groupes, et l'*Analyse en Composantes Principales (PCA)*, qui projette les données sur les axes de plus grande variance sans tenir compte des classes.

Dans notre cas, la projection LDA a été privilégiée car elle prend en compte l'information de la variable cible (la maladie). Les résultats montrent une séparation relativement nette entre certaines classes, notamment entre la *Dengue* et la *Malaria* d'une part, et les pathologies bénignes comme *Normal Fever* ou *Runny Nose* d'autre part. La projection linéaire révèle que les maladies se répartissent en plusieurs groupes distincts dans l'espace des deux premières composantes discriminantes.




FIGURE 5.2 – Projection linéaire des données utilisant LDA dans Orange, montrant la séparation des différentes maladies dans un espace à deux dimensions.

Les points colorés selon la maladie montrent que la Fièvre (Fever) joue un rôle clé dans la séparation, comme en témoigne l'échelle de couleur associée à cette variable. Les cas de dengue et de paludisme, caractérisés par des températures élevées, se positionnent à une extrémité du graphique, tandis que les patients souffrant de rhume ou de fièvre normale occupent la région opposée. Les courbatures et l'asthme occupent des positions intermédiaires, avec une certaine dispersion.

Cette visualisation confirme que les symptômes sélectionnés permettent une discrimination satisfaisante entre les huit pathologies, bien que certaines classes présentent un chevauchement, suggérant que des modèles plus complexes (comme les arbres de décision ou les forêts aléatoires) pourraient être nécessaires pour capturer pleinement les relations subtiles entre les symptômes et les maladies.

5.3 Matrice de corrélation (Heat Map)

Après avoir identifié les variables les plus discriminantes et visualisé leur séparabilité via la projection linéaire, nous avons utilisé le widget *Heat Map* pour explorer les corrélations entre les différents symptômes. Cette visualisation permet de détecter d'éventuelles redondances ou associations fortes entre les variables, informations précieuses pour affiner la sélection des caractéristiques et éviter la multicollinéarité dans les modèles.

La *heat map* présentée ci-dessus représente la matrice de corrélation entre les cinq symptômes. Les couleurs varient du bleu (corrélation négative) au vert (corrélation nulle) et au jaune (corrélation positive forte). L'analyse révèle des corrélations globalement modérées entre les symptômes, ce qui indique que chaque variable apporte une information relativement unique et complémentaire.




FIGURE 5.3 – Matrice de corrélation des symptômes à l’aide du widget Heat Map dans Orange, illustrant les relations entre les variables.

La *heat map* présentée ci-dessus représente la matrice de corrélation entre les cinq symptômes. Les couleurs varient du bleu (corrélation négative) au vert (corrélation nulle) et au jaune (corrélation positive forte). L’analyse révèle des corrélations globalement modérées entre les symptômes, ce qui indique que chaque variable apporte une information relativement unique et complémentaire.

On observe notamment une corrélation positive entre la *Fièvre* (*Fever*) et la *Fatigue*, reflétant le fait que les patients fébriles ressentent généralement un état de fatigue important, ce qui est cliniquement cohérent. De même, une association modérée est visible entre les *Maux de tête* (*Headache*) et les *Douleurs corporelles* (*Body_Pain*), deux symptômes souvent présents simultanément dans des pathologies comme la dengue ou le paludisme. En revanche, la *Toux* (*Cough*) présente des corrélations plus faibles avec les autres symptômes, confirmant son caractère relativement indépendant.

L’absence de corrélations très fortes (supérieures à 0,8) entre les variables est un résultat encourageant : elle indique qu’il n’y a pas de redondance majeure entre les symptômes, ce qui justifie leur conservation pour la modélisation. Chaque symptôme apporte une contribution spécifique à la discrimination des maladies, et leur combinaison permet de capturer efficacement les différences entre les pathologies. Cette analyse de corrélation complète ainsi les résultats du classement des variables et de la projection linéaire, offrant une vision globale de la structure des données avant d’aborder la modélisation prédictive.

5.4 Analyse en Composantes Principales (PCA)

L’Analyse en Composantes Principales (PCA) est une technique de réduction de dimension qui permet de transformer les variables originales en un nouvel ensemble de composantes non corrélées, tout en préservant le maximum d’information. Cette méthode

est particulièrement utile pour visualiser la structure des données dans un espace réduit et pour identifier les axes de variation les plus importants.

Le widget *PCA* d'Orange a été appliqué aux données normalisées afin d'explorer la variance expliquée par chaque composante et d'évaluer la qualité de la représentation en deux dimensions.




FIGURE 5.4 – Projection des données en deux dimensions à l'aide de l'Analyse en Composantes Principales (PCA) dans Orange, illustrant la variance expliquée et la structure des données.

L'analyse PCA révèle que les deux premières composantes principales expliquent 79% de la variance totale des données. La première composante (PC1) capture environ 60% de la variance, tandis que la seconde (PC2) en explique environ 19%. Les trois composantes restantes ne contribuent que marginalement à l'explication de la variance, avec des proportions décroissantes.

Ce résultat est particulièrement satisfaisant : il signifie qu'une projection en deux dimensions permet de conserver près de 80% de l'information contenue dans les cinq symptômes initiaux. Cette forte concentration de la variance dans les deux premières composantes indique que les données présentent une structure sous-jacente relativement simple, où les symptômes sont corrélés entre eux de manière cohérente.

La première composante est très probablement associée à la gravité globale des symptômes ou à la présence de fièvre, tandis que la seconde pourrait distinguer les profils respiratoires (toux) des profils douloureux (douleurs corporelles). La réduction de dimen-

sion permet ainsi de simplifier la représentation des données tout en conservant l'essentiel de l'information.

Cette analyse confirme que les cinq symptômes sont suffisamment redondants pour être résumés par un nombre restreint de facteurs, mais également suffisamment distincts pour permettre une classification fine des maladies. Elle justifie l'utilisation de modèles qui exploitent l'ensemble des variables, tout en offrant une perspective intéressante sur la structure latente des données.

5.5 Visualisation des composantes principales (Scatter Plot PCA)

Après avoir appliqué l'Analyse en Composantes Principales (PCA), nous avons visualisé les données projetées sur les deux premières composantes principales à l'aide d'un Scatter Plot. Cette représentation permet d'observer la répartition des patients dans un espace réduit et d'évaluer visuellement la séparabilité des différentes maladies.




FIGURE 5.5 – Projection des données sur les deux premières composantes principales (PCA) sous forme de Scatter Plot, illustrant la répartition des patients et la séparabilité des différentes maladies dans un espace réduit.

Le graphique ci-dessus présente la projection des 5 000 patients selon les deux premières composantes principales (PC1 et PC2), qui capturent ensemble 79% de la variance totale des données. Chaque point est coloré selon la maladie du patient.

L'observation révèle que les différentes maladies forment des regroupements relativement distincts, bien que certains chevauchements subsistent. La *Dengue* et la *Malaria* se positionnent à une extrémité du graphique (plutôt vers PC1 positive), tandis que le *Common Cold* et l'*Asthma* occupent des zones différentes. Le *Body Ache* se situe dans

une région intermédiaire, partiellement superposée avec d'autres classes, ce qui suggère que ce symptôme partage des caractéristiques avec d'autres pathologies.

Cette visualisation confirme plusieurs enseignements clés :

- PC1 semble principalement associée à la fièvre et à la fatigue, car elle sépare nettement les maladies fébriles (*Dengue*, *Malaria*) des pathologies non fébriles (*Asthma*, *Runny Nose*).
- PC2 distingue probablement les profils respiratoires (*Cough*) des profils douloureux (*Body Ache*).
- Certaines maladies comme le *Common Cold* présentent une dispersion plus large, ce qui indique une variabilité symptomatique plus importante.
- Les chevauchements observés entre certaines classes suggèrent que la classification parfaite est difficile à atteindre, même avec des modèles complexes.

Malgré quelques zones de confusion, la séparation globale des classes est satisfaisante et confirme la pertinence des symptômes sélectionnés pour la prédiction des maladies. Cette visualisation prépare également le terrain pour la modélisation prédictive, en indiquant que des modèles non linéaires (comme les arbres de décision ou les forêts aléatoires) pourraient être nécessaires pour capturer pleinement les frontières complexes entre certaines pathologies.

Chapitre 6

Modélisation et évaluation des performances

Après avoir exploré et préparé les données, nous abordons maintenant la phase de modélisation prédictive. Cette étape consiste à entraîner plusieurs algorithmes d'apprentissage automatique sur notre dataset afin de prédire la maladie d'un patient à partir de ses symptômes. L'objectif est double : identifier le modèle le plus performant et évaluer sa capacité à généraliser sur de nouvelles données.

6.1 Modèles supervisés (Test et Score)

Après avoir préparé les données, nous avons entraîné et évalué six modèles de classification pour prédire la maladie d'un patient à partir de ses cinq symptômes. Le widget Test et Score d'Orange a été utilisé avec une validation croisée à 10 folds pour assurer une évaluation robuste des performances.

MODÈLE	DESCRIPTION
k-NN (k-Nearest Neighbors)	Algorithme non paramétrique qui classe un patient en fonction des classes majoritaires de ses k voisins les plus proches dans l'espace des caractéristiques.
Naive Bayes	Modèle probabiliste basé sur le théorème de Bayes, supposant l'indépendance conditionnelle des symptômes. Rapide et efficace pour les données de grande dimension.
Random Forest	Méthode d'ensemble qui construit une multitude d'arbres de décision et combine leurs prédictions pour améliorer la robustesse et la précision.
Neural Network	Réseau de neurones artificiels capable d'apprendre des relations non linéaires complexes entre les symptômes et les maladies.
SVM (Support Vector Machine)	Algorithme qui cherche l'hyperplan optimal séparant au mieux les différentes classes dans un espace de grande dimension.
Logistic Regression	Modèle linéaire qui estime la probabilité d'appartenance à chaque classe. Interprétable et servant de référence pour les modèles plus complexes.

FIGURE 6.1 – Les modèles Utiliser

6.1.1 nalyse des résultats

MÉTRIQUE	K-NN	NAIVE BAYES	RANDOM FOREST	NEURAL NETWORK	SVM	LOGISTIC REGRESSION
AUC	0.960	0.934	0.978	0.969	0.924	0.950
CA (Accuracy)	0.923	0.884	0.944	0.927	0.880	0.904
F1-score	0.728	0.504	0.799	0.725	0.460	0.622
Precision	0.651	0.541	0.722	0.685	0.525	0.614
Recall	0.826	0.472	0.896	0.770	0.410	0.630
MCC	0.690	0.440	0.773	0.685	0.397	0.567
Temps (Train)	0.137s	0.073s	7.221s	32.177s	3.945s	1.667s

FIGURE 6.2 – Les Modeles Resultats

Le *Random Forest* se distingue comme le modèle le plus performant sur l'ensemble des métriques, avec une accuracy de 94,4% et un AUC de 0,978. Il présente également les meilleurs F1-score (0,799), Recall (0,896) et MCC (0,773), ce qui indique une excellente capacité à discriminer les huit maladies. Son temps d'entraînement (7,2 secondes) reste raisonnable.

Le *k-NN* obtient de très bonnes performances (accuracy de 92,3%, AUC de 0,960) avec un temps d'entraînement très faible (0,137s). Il constitue une excellente alternative lorsque la rapidité est privilégiée. Le *Neural Network* affiche des résultats solides (accuracy 92,7%, AUC 0,969) mais avec un temps d'entraînement beaucoup plus long (32 secondes).

Le *Naive Bayes* et la *Logistic Regression* offrent des performances correctes mais inférieures (accuracy respective de 88,4% et 90,4%). Le *SVM* présente les résultats les plus faibles (accuracy 88%, AUC 0,924) et un F1-score très bas (0,460), suggérant une difficulté à gérer la complexité du problème de classification multiclasse avec 8 catégories.

La matrice de comparaison des modèles (probabilité qu'un modèle soit meilleur qu'un autre en AUC) confirme que le *Random Forest* est statistiquement supérieur à tous les autres modèles, avec des probabilités très élevées (proches de 1). Le *Naive Bayes*, la *Logistic Regression* et le *SVM* montrent des performances significativement inférieures.

6.1.2 Conclusion sur les modèles supervisés

Le *Random Forest* est le modèle le plus performant pour ce problème de diagnostic médical, alliant une excellente précision (94,4%) à une bonne capacité de généralisation (AUC 0,978). Ces résultats confirment la pertinence des cinq symptômes pour prédire les maladies, et suggèrent que des modèles d'ensemble non linéaires sont particulièrement adaptés à ce type de données médicales.

6.2 Analyse approfondie des performances

Après avoir évalué les modèles via le widget Test et Score, nous avons utilisé trois widgets complémentaires pour analyser plus en détail leurs performances : la Matrice de Confusion, l'Analyse ROC et la Courbe de Performance. Ces outils permettent respectivement d'examiner les erreurs de classification, d'évaluer la capacité discriminante des modèles et de visualiser leurs performances selon différents seuils de décision.

6.2.1 Matrice de confusion

MALADIE	VRAIS POSITIFS	ERREURS PRINCIPALES	OBSERVATIONS
Asthma	516/625 (82,6%)	Confusion avec Cough (85) et Common Cold (24)	L'asthme est parfois confondu avec d'autres pathologies respiratoires
Body Ache	625/625 (100%)	Aucune erreur	Parfaitement classifié, symptôme très discriminant
Common Cold	437/625 (69,9%)	Confusion avec Asthma (133) et Normal Fever (20)	Pathologie la plus difficile à classer
Cough	466/625 (74,6%)	Confusion avec Asthma (144) et Common Cold (15)	Confusion avec d'autres affections respiratoires
Dengue	619/625 (99%)	Confusion avec Malaria (6)	Très bien classifié
Malaria	615/625 (98,4%)	Confusion avec Dengue (10)	Très bien classifié
Normal Fever	599/625 (95,8%)	Confusion avec Runny Nose (22)	Bien classifié
Runny Nose	612/625 (97,9%)	Confusion avec Normal Fever (13)	Très bien classifié

FIGURE 6.3 – Matrice de Confusion

La matrice de confusion révèle plusieurs enseignements importants :

Body Ache est parfaitement classifié (100%), ce qui confirme que les douleurs corporelles intenses sont un symptôme très discriminant pour cette pathologie.

Dengue et *Malaria* sont également très bien classifiées (>98%), grâce à des profils symptomatiques distinctifs (fièvre élevée, fatigue intense).

Common Cold est la maladie la moins bien classifiée (69,9%), avec des confusions fréquentes avec l'*Asthma* (133 cas) et la *Normal Fever* (20 cas). Cette difficulté s'explique par le chevauchement des symptômes entre ces pathologies bénignes.

Asthma et *Cough* présentent des confusions mutuelles significatives, ce qui est cohérent avec le fait que la toux est un symptôme commun aux deux affections.

6.2.2 Courbes ROC (Receiver Operating Characteristic)

MODÈLE	AUC	INTERPRÉTATION
Random Forest	~0,99	Excellente discrimination
k-NN	~0,98	Très bonne discrimination
Neural Network	~0,97	Très bonne discrimination
Naive Bayes	~0,93	Bonne discrimination
Logistic Regression	~0,95	Bonne discrimination
SVM	~0,92	Bonne discrimination

FIGURE 6.4 – Courbes ROC (Receiver Operating Characteristic)

Les courbes ROC confirment la supériorité du *Random Forest* et du *k-NN* pour la discrimination des maladies. Les AUC proches de 1 indiquent que ces modèles sont capables de distinguer très efficacement les patients atteints d'une maladie donnée de ceux qui ne le sont pas.

Le *Naive Bayes* et le *SVM*, bien que performants, présentent des AUC légèrement inférieurs, ce qui suggère une capacité discriminante moindre, en cohérence avec les résultats obtenus dans la matrice de confusion.

6.2.3 Courbes de performance (Performance Curve)

Les courbes de performance, également appelées courbes de *Lift* ou courbes de gains cumulés, permettent d'évaluer l'efficacité d'un modèle en termes de gain par rapport à un modèle aléatoire. Elles sont particulièrement utiles pour comparer les modèles selon différents seuils de probabilité.

MODÈLE	SCORE (AREA UNDER THE CURVE)
k-NN	4,357
Random Forest	4,246
Neural Network	2,768
Naive Bayes	2,517
SVM	2,356

FIGURE 6.5 – Courbes de performance (Performance Curve)

Les courbes de performance montrent que le *k-NN* et le *Random Forest* sont les modèles les plus performants en termes de gain cumulé, avec des scores respectifs de 4,357 et 4,246. Cela signifie qu'ils sont capables de concentrer une proportion élevée de vrais positifs dans les premiers percentiles de prédiction. Le *Neural Network*, le *Naive Bayes* et le *SVM* présentent des performances inférieures, confirmant les résultats précédents.

La courbe de *Lift* montre également que tous les modèles surpassent significativement un modèle aléatoire (représenté par la ligne de base), ce qui valide la pertinence des symptômes pour la prédiction des maladies.

6.2.4 Synthèse des évaluations

CRITÈRE	MEILLEUR MODÈLE	OBSERVATIONS
Accuracy	Random Forest (94,4%)	Très bonne performance globale
AUC	Random Forest (0,978)	Excellente capacité discriminante
F1-score	Random Forest (0,799)	Bon équilibre précision/rappel
Temps d'entraînement	k-NN (0,137s)	Modèle très rapide
Matrice de confusion	Random Forest	Peu d'erreurs, classes bien séparées
Courbes ROC	Random Forest	AUC proche de 1 pour toutes les classes
Courbes de performance	k-NN (4,357)	Très bon gain cumulé

FIGURE 6.6 – Synthèse des évaluations

Les trois outils d'évaluation convergent vers la même conclusion : le *Random Forest* est le modèle le plus performant pour ce problème de diagnostic médical, suivi de près par le *k-NN*. Ces résultats confirment que les cinq symptômes sélectionnés sont suffisants pour prédire efficacement les huit maladies, avec une précision dépassant 94% pour le meilleur modèle.

6.3 Clustering non supervisé (K-means)

Parallèlement à l'approche supervisée, nous avons exploré une méthode non supervisée pour vérifier si les données se structurent naturellement en groupes correspondant aux maladies. Le *clustering K-means* est un algorithme de partitionnement qui regroupe les patients en fonction de la similarité de leurs profils symptomatiques, sans utiliser l'information sur leur maladie. Cette approche permet de valider la cohérence interne des données et d'identifier d'éventuels sous-groupes cliniques.




FIGURE 6.7 – Résultat du clustering K-means appliqué aux données patients, illustrant la formation de groupes basés sur la similarité des symptômes dans un espace réduit.

L'algorithme K-means a été configuré avec les paramètres suivants :

PARAMÈTRE	VALEUR	RÔLE
Nombre de clusters	8	Correspond au nombre de maladies
Normalisation	Activée	Standardisation des variables
Initialisation	K-means++	Améliore la convergence
Nombre de ré-exécutions	10	Évite les optimums locaux
Itérations maximales	300	Assure la convergence

FIGURE 6.8 – K-means parametres

Le graphique Scatter Plot (2) présente la projection des patients sur les deux premières composantes principales (PC1 et PC2), colorés selon leur cluster d'appartenance. Les 8 clusters (C1 à C8) sont représentés par des couleurs distinctes.




FIGURE 6.9 – Projection des patients sur les deux premières composantes principales (PC1 et PC2) avec coloration selon les 8 clusters (C1 à C8) obtenus par K-means.

Les clusters sont relativement bien séparés dans l'espace des deux premières composantes principales, ce qui indique que les patients regroupés par K-means présentent des profils symptomatiques similaires.

Certains clusters sont plus compacts (C1, C2, C3), suggérant une homogénéité interne élevée, tandis que d'autres (C5, C6) présentent une dispersion plus importante.

La répartition des clusters correspond globalement aux maladies identifiées dans l'analyse supervisée, confirmant la cohérence des données.

6.3.1 Visualisation des clusters (Scatter Plot)

Le Silhouette Plot permet d'évaluer la qualité du clustering en mesurant pour chaque patient sa similarité avec les membres de son propre cluster par rapport aux autres clusters. Un coefficient de silhouette proche de 1 indique que le patient est bien regroupé, tandis qu'une valeur proche de -1 suggère un mauvais regroupement.




FIGURE 6.10 – Visualisation des clusters (Scatter Plot)

La majorité des patients présentent des coefficients de silhouette positifs, indiquant une bonne cohésion intra-cluster.

La largeur des barres, qui représente la taille de chaque cluster, montre une répartition relativement équilibrée des patients entre les 8 clusters.

Les clusters correspondant aux maladies les plus distinctives (comme Body Ache ou Dengue) présentent des silhouettes plus élevées, confirmant leur bonne séparation.

Certains patients présentent des coefficients proches de zéro, suggérant des profils frontaliers entre plusieurs clusters, ce qui est cohérent avec les confusions observées dans la matrice de confusion supervisée.

Le clustering K-means confirme que les données présentent une structure naturelle en 8 groupes correspondant globalement aux maladies. Les résultats du clustering sont cohérents avec ceux de la classification supervisée :

Les maladies bien séparées (Body Ache, Dengue, Malaria) forment des clusters compacts et bien distincts.

Les maladies avec des symptômes chevauchants (Asthma, Common Cold, Cough) présentent des clusters moins nets, avec des patients en situation frontalière.

Le coefficient de silhouette moyen est satisfaisant, indiquant que la partition en 8 clusters est pertinente.

Cette analyse non supervisée valide la qualité du dataset et confirme que les symptômes sélectionnés permettent de discriminer efficacement les huit pathologies, même sans information préalable sur la maladie.

Chapitre 7

Extraction de connaissances

7.1 L'arbre de décision

L'arbre de décision est un modèle d'apprentissage supervisé qui construit une structure arborescente pour prendre des décisions de classification. Chaque nœud interne correspond à un test sur une variable (symptôme), chaque branche représente le résultat du test, et chaque feuille correspond à une classe (maladie). Sa principale force réside dans son interprétabilité : il permet de visualiser clairement le cheminement décisionnel menant à un diagnostic, ce qui en fait un outil précieux pour l'extraction de connaissances dans un contexte médical.

L'arbre de décision a été construit à partir des données prétraitées, après avoir séparé les variables explicatives (les cinq symptômes) de la variable cible (la maladie) via le widget *Select Columns*. Les paramètres de construction ont été définis comme suit :




FIGURE 7.1 – Select Columns




FIGURE 7.2 – Tree

- Parametre de l'arbre :

PARAMÈTRE	VALEUR	RÔLE
Arbre binaire	Activé	Chaque nœud a deux branches
Instances minimales par feuille	1	Permet des feuilles très spécifiques
Profondeur maximale	5	Limite la complexité pour éviter le sur-apprentissage
Arrêt à 95% de pureté	95%	Arrête la croissance quand un nœud est majoritairement d'une classe

FIGURE 7.3 – Parametre de l'arbre

L'arbre obtenu comprend 31 nœuds et 16 feuilles, pour une profondeur maximale de 5 niveaux. Cette structure relativement compacte facilite l'interprétation des règles de décision.




FIGURE 7.4 – Arbre de décision

Résumé simplifié de l'arbre de décision

Règles identifiées

L'arbre de décision a permis d'extraire 16 règles de diagnostic. Voici les 5 principales :

RÈGLE	CONDITION	DIAGNOSTIC	FIABILITÉ
1	Forte fièvre (>99.5°F) + Douleurs intenses (>5.96/10)	Body Ache	100%
2	Forte fièvre + Fatigue importante + Peu de toux	Malaria	100%
3	Pas de forte fièvre + Peu de toux + Pas de fatigue	Normal Fever	95,8%
4	Pas de forte fièvre + Toux importante + Fatigue	Common Cold	100%
5	Pas de forte fièvre + Toux importante + Pas de fatigue	Runny Nose	100%

FIGURE 7.5 – Règle extrait de l'arbre

Ce que cela signifie en pratique ?

— La fièvre est le premier indicateur

Le médecin commence par vérifier la température du patient. Si elle dépasse 99,5°F (environ 37,5°C), il s'oriente vers des maladies graves comme le paludisme ou la dengue. Si elle est normale ou légèrement élevée, il examine d'autres symptômes.

— Les douleurs corporelles indiquent les courbatures

Si le patient a de la fièvre ET des douleurs corporelles très intenses (>5,96/10), il s'agit presque certainement de courbatures (Body Ache). C'est une règle parfaite : 625 patients sur 625 ont été correctement classés.

— **La fatigue et la toux permettent de différencier les maladies bénignes**

Pour les patients sans forte fièvre :

- Toux importante + Fatigue → Rhume (Common Cold)
- Toux importante + Pas de fatigue → Écoulement nasal (Runny Nose)
- Pas de toux + Pas de fatigue → Fièvre normale (Normal Fever)

En résumé, l'arbre de décision confirme que :

- Les 5 symptômes sont suffisants pour diagnostiquer les 8 maladies.
- La fièvre est le symptôme le plus important pour orienter le diagnostic.
- La toux et la fatigue aident à distinguer les pathologies bénignes entre elles.
- Les douleurs corporelles sont le marqueur clé des courbatures.
- 4 maladies (Body Ache, Malaria, Common Cold, Runny Nose) peuvent être diagnostiquées avec certitude (100%) à partir des règles extraites.

Cet arbre de décision pourrait servir d'outil d'aide au diagnostic rapide, fiable et facile à utiliser, même par un personnel médical non spécialisé en intelligence artificielle.

En résumé, l'arbre de décision confirme que :

- Les 5 symptômes sont suffisants pour diagnostiquer les 8 maladies.
- La fièvre est le symptôme le plus important pour orienter le diagnostic.
- La toux et la fatigue aident à distinguer les pathologies bénignes entre elles.
- Les douleurs corporelles sont le marqueur clé des courbatures.
- 4 maladies (Body Ache, Malaria, Common Cold, Runny Nose) peuvent être diagnostiquées avec certitude (100%) à partir des règles extraites.

Cet arbre de décision pourrait servir d'outil d'aide au diagnostic rapide, fiable et facile à utiliser, même par un personnel médical non spécialisé en intelligence artificielle.

7.2 Classification Ascendante Hiérarchique (CAH)

La Classification Ascendante Hiérarchique (CAH) est une méthode de clustering qui construit une hiérarchie de regroupements en fusionnant progressivement les individus les plus proches. Contrairement à K-means qui partitionne les données en un nombre fixe de clusters, la CAH produit un dendrogramme qui visualise l'ensemble des niveaux de regroupement possibles, offrant ainsi une vue complète de la structure hiérarchique des données.

Cette approche est particulièrement intéressante pour l'extraction de connaissances car elle permet d'observer comment les patients se regroupent naturellement selon la similarité de leurs symptômes, sans imposer un nombre de clusters prédéfini. Dans un contexte médical, cela peut révéler des relations insoupçonnées entre différentes pathologies ou identifier des sous-groupes cliniques.




FIGURE 7.6 – Classification Ascendante Hiérarchique (CAH)

Calcul des distances (Distances)

La première étape de la CAH consiste à calculer les similarités entre les patients. Le widget Distances a été utilisé pour cela.




FIGURE 7.7 – Distance

Paramétrage :

PARAMÈTRE	VALEUR	RÔLE
Comparaison	Rows	Comparer les patients entre eux
Distance Metric	Euclidean	Mesure de similarité basée sur la distance géométrique
Normalisation	Activée	Les variables sont normalisées pour une comparaison équitable

FIGURE 7.8 – Distance Parametres

Le choix de la distance euclidienne normalisée est pertinent car les symptômes sont mesurés sur des échelles différentes (la fièvre en °F et les autres symptômes sur une échelle

de 0 à 10). La normalisation permet de donner un poids équitable à chaque symptôme dans le calcul des distances, évitant ainsi que la fièvre ne domine artificiellement la mesure de similarité.

La matrice de distances obtenue ($5\,000 \times 5\,000$) sert de base à la construction du dendrogramme. Les patients avec des profils symptomatiques similaires auront des distances faibles et seront regroupés en premier.

7.2.1 Construction du dendrogramme (Hierarchical Clustering)

Le widget Hierarchical Clustering construit le dendrogramme en fusionnant progressivement les patients les plus proches selon la méthode choisie.




FIGURE 7.9 – Hierarchical Clustering

Paramétrage :

PARAMÈTRE	VALEUR	RÔLE
Linkage	Average	Utilise la distance moyenne entre les groupes pour la fusion
Annotations	Disease	Colore les patients selon leur maladie réelle
Color by	Disease	Visualise la correspondance avec les maladies

FIGURE 7.10 – Hierarchical Clustering Informations

Le dendrogramme obtenu présente plusieurs caractéristiques intéressantes :

Structure hiérarchique en niveaux : Le graphique montre les différents niveaux de regroupement, des patients individuels (en bas) jusqu'à un seul cluster (en haut). La hauteur des barres verticales représente la distance à laquelle les regroupements sont effectués.

Regroupements naturels : On observe que les patients atteints de la même maladie ont tendance à se regrouper ensemble, ce qui confirme que les symptômes sont cohérents avec les diagnostics. Par exemple, les patients *Body Ache* forment un groupe distinct, tout comme les patients *Dengue* et *Malaria*.

Séparation des pathologies fébriles et non fébriles : Le dendrogramme montre une séparation nette entre les pathologies fébriles (*Dengue*, *Malaria*, *Body Ache*) et les pathologies non fébriles (*Asthma*, *Common Cold*, *Cough*, *Normal Fever*, *Runny Nose*), ce qui confirme le rôle discriminant de la fièvre.

Relations entre pathologies : Certaines maladies sont plus proches dans le dendrogramme, suggérant des profils symptomatiques similaires. Par exemple, *Asthma* et *Cough* se regroupent souvent, ce qui est cohérent avec le fait que la toux est un symptôme commun aux deux affections.

Visualisation des clusters (Scatter Plot)

Le scatter plot final représente les patients projetés sur les deux premières composantes principales (PC1 et PC2), colorés selon leur maladie réelle. Cette visualisation permet de valider visuellement la correspondance entre les clusters hiérarchiques et les maladies.




FIGURE 7.11 – Visualisation des clusters (Scatter Plot)

OBSERVATION	SIGNIFICATION
Regroupements distincts	Les maladies forment des nuages de points relativement séparés, confirmant la bonne discrimination
PC1 (axe horizontal)	Sépare principalement les pathologies fébriles (à droite) des pathologies non fébriles (à gauche)
PC2 (axe vertical)	Distingue les profils respiratoires (haut) des profils douloureux (bas)
Chevauchements	Certaines pathologies comme Common Cold et Asthma présentent des zones de recouvrement, ce qui explique les confusions observées dans la classification supervisée

FIGURE 7.12 – Les informations sur Visualisation des clusters

Chapitre 8

Conclusion

Conclusion : La Classification Ascendante Hiérarchique confirme la structure naturelle des données en 8 groupes correspondant aux maladies. Le dendrogramme révèle une hiérarchie cohérente où les pathologies fébriles se distinguent nettement des pathologies non fébriles. Cette analyse non supervisée valide la pertinence des symptômes sélectionnés et renforce la confiance dans les résultats obtenus par les modèles supervisés.

L'apport principal de la CAH réside dans sa capacité à visualiser les relations hiérarchiques entre les pathologies, offrant une perspective complémentaire à la classification supervisée. Elle permet de comprendre non seulement quelles maladies sont bien séparées, mais aussi quelles pathologies partagent des similitudes cliniques, ce qui peut guider la recherche médicale ou l'amélioration des critères diagnostiques.